

УТВЕРЖДАЮ

Проректор по науке и инновациям
ТОО «Astana IT University»

_____ Ф.И.О.

_____ подпись

«_____» _____ 2026 г.

УТВЕРЖДАЮ

должностное лицо принимающей организации
ЧК «SHAI Ltd.»

наименование принимающей организации

_____ Ф.И.О.

_____ подпись

«_____» _____ 2026 г.

Программа научной стажировки магистранта

Shaumen Angsar Askhatuly

Образовательная программа: 7M06108 Applied Artificial Intelligence

Год обучения: 1 курс, 2025-2026

Тема магистерской диссертации: «Noise Filtering Methods for Stefan Problem Datasets»

Научный руководитель: Қасабек Самат Абдихамитұлы

Место прохождения научной стажировки: ЧК «SHAI Ltd.», г. Астана, Казахстан

Период прохождения стажировки: 16.05.2026 – 30.05.2026

Астана, 2026

Содержание программы стажировки:

I. Образовательный компонент

1. **Тема 1:** Изучение state-of-the-art архитектур систем распознавания речи (ASR) для казахского языка (FastConformer, QuartzNet, Whisper, Soyle).
2. **Тема 2:** Подходы к обработке речи с переключением кодов (code-switching, Shala-Kazakh) и оценке метрик качества распознавания (WER, RTF).
3. **Тема 3:** Анализ и предварительная обработка акустических речевых корпусов: токенизация, классификация и извлечение слов-паразитов (discourse fillers, interjections) для подготовки качественных датасетов.
4. **Тема 4:** Изучение современных Flow Matching архитектур для синтеза речи (F5-TTS, Tote-TTS), заменяющих авторегрессионные методы.
5. **Тема 5:** Методы оптимизации и развертывания low-latency TTS моделей на базе ONNX runtime (Piper TTS).

II. Научный компонент

1. **Работа 1:** Бенчмаркинг и оценка локальных STT моделей на формальной (Pure-Kazakh) и разговорной (Shala-Kazakh) речи.
2. **Работа 2:** Разработка пайплайна предварительной очистки и классификации слов-паразитов из датасета MFA (408 010 сэмплов).
3. **Работа 3:** Исследование Flow Matching пайплайна (текст → фонемайзер → Continuous Flow Matcher → ONNX/HiFi-GAN).
4. **Работа 4:** Развертывание оптимизированных ONNX-моделей для синтеза казахской речи с низкой задержкой (менее 50мс).

Понедельный план стажировки

Дата	Время	Наименование работ	Ответственный
16.05 – 22.05	10:00-18:00	Исследование STT архитектур и бенчмаркинг моделей распознавания речи	Senior Researcher
25.05 – 30.05	10:00-18:00	Обработка датасета слов-паразитов и развертывание low-latency TTS	Senior Researcher

СОГЛАСОВАНО:

Научный руководитель: _____ Қасабек С. А.

Научный руководитель с организации: _____ Senior Researcher

Директор школы ОП: _____ Сергазиев М. Ж.

ТОО «Astana IT University»

Школа искусственного интеллекта и науки о данных

УТВЕРЖДАЮ

Директор Школы искусственного интеллекта и науки о данных

_____ Сергазиев М. Ж.

«_____» _____ 2026 г.

Обсуждено на заседании протокол № _____

от «_____» _____ 2026 г.

ОТЧЕТ
О НАУЧНОЙ СТАЖИРОВКЕ

Магистрант: Shaumen Angsar Askhatuly, AAI-2501M

Образовательная программа: Applied Artificial Intelligence

Срок обучения по программе магистратуры: с «01» 09 2025г. по «30» 06 2027г.

Год обучения: 1 курс, 2025-2026

Тема магистерской диссертации: Noise Filtering Methods for Stefan Problem Datasets

Научный руководитель: Қасабек Самат Абдихамитұлы

Место прохождения научной стажировки (организация, страна, город):

ЧК «SHAI Ltd.», Казахстан, Астана

Период прохождения стажировки: с «16» 05 2026г. по «30» 05 2026г.

Астана, 2026

Отчет о научной стажировке

1. Виды выполненных работ в соответствии с планом научной стажировки, значимость полученных результатов

№ п/п	Наименование работ	Полученные результаты
1	Исследование STT Model Exploration и пула кандидатов	Каталогизировано 5 ASR моделей. Проведен бенчмаркинг на Shala-Kazakh, лучшая модель – Soyle (RTF 0.05).
2	Локальный бенчмаркинг STT (Local STT Testing)	Реализован интерактивный стенд. Вычислены RTF и WER для чистой и смешанной (Shala-Kazakh) казахской речи.
3	Пайплайн обработки слов-паразитов (Filler Preprocessing)	Очищен датасет на 408 010 сэмплов. Извлечено 37 013 discourse fillers и 4 942 expressive interjections для обучения кастомных TTS моделей.
4	Исследование Flow Matching архитектуры (TTS Flow Matching)	Изучены архитектуры F5-TTS и Tote-TTS. Построен пайплайн нормализации текста и Continuous Flow Matcher.
5	Развертывание low-latency TTS	Интегрированы оптимизированные ONNX модели с движком Piper TTS. Достигнута задержка синтеза менее 50мс.

Отзыв магистранта о результативности и эффективности научной стажировки

В ходе научной стажировки в ЧК «SHAI Ltd.» были изучены современные подходы к распознаванию (ASR) и синтезу речи (TTS) для казахского языка. Основное внимание было уделено исследованию устойчивости акустических моделей к разговорной речи с переключением кодов (Shala-Kazakh) и оптимизации архитектур синтеза на основе Flow Matching.

В результате стажировки был реализован стенд для бенчмаркинга STT моделей, разработан робастный пайплайн очистки датасета от слов-паразитов, а также успешно развернут низколатентный движок синтеза речи на базе ONNX, обеспечивающий задержку менее 50мс. Полученные знания и практические навыки в области речевых технологий, конвейеров глубокого обучения и оптимизации вычислений являются весьма полезными для дальнейшей научно-исследовательской работы.

Магистрант _____ Shaumen A. A.

Научный руководитель _____ Қасабек С. А.

Руководитель базы стажировки (ответственный)

_____ (подпись, ФИО)

« ____ » _____ 2026г.